

А/В тест: Paywall після онбордингу (А vs В "-50%")

Контекст:

- Група А: стандартний екран підписки \$4.99
- Група В: та ж підписка \$4.99, але з повідомленням -50%
- Основна метрика: конверсія в покупку (purchase/users)

Гіпотези:

- H0: конверсія в групі В = конверсії в групі А;
- H1: конверсія в групі В $\neq$ конверсії в групі А.

Припускаємо, що допоміжні метрики не змінилися, ому рішення приймаємо на основі конверсії.

```
In [17]: import pandas as pd
import numpy as np
import matplotlib.pyplot as plt

df = pd.read_csv(r"C:\Users\ПК\Desktop\ДЗ Тестування АБ\ab_test_data.csv")

df.head, df.shape
#Переконуємось що файл зчитався і ми бачимо колонки
```

```
Out[17]: (<bound method NDFrame.head of
timestamp \
0      7f6833e6-1141-4f20-b4b2-f1e31019b1fd  2023-07-04 04:40:55.848109
1      e6a6e960-d3f3-4074-a516-ba1e609b211e  2023-07-06 00:26:45.486187
2      4d3fbfa5-6847-410a-bac2-477f01d5f400  2023-07-10 20:24:33.639464
3      361457d9-a044-48f7-981c-d67dc3861679  2023-07-20 07:04:49.957013
4      285cd63d-7d03-427f-a062-1fa2dd2e77d6  2023-07-19 23:27:50.116680
...
19993  6763ae9a-515c-473e-af00-0d9c4f6a5bc7  2023-07-06 03:27:37.041104
19994  ac5600f2-4d16-4503-b115-f1a96728b6d1  2023-07-03 04:20:48.572143
19995  5a8b2630-209b-4d83-b47f-0f3d9dd568a8  2023-07-23 16:23:49.211910
19996  b572d68b-26ac-432b-9f88-83e0fdee4ca1  2023-07-03 18:26:20.880675
19997  3d313adc-c8d6-43f2-8b4e-e267b194ff78  2023-07-19 13:15:37.562340

test_group  conversion
0           a           0
1           b           0
2           b           0
3           b           0
4           b           0
...         ...         ...
19993       b           0
19994       a           0
19995       b           1
19996       b           0
19997       b           0

[19998 rows x 4 columns]>,
(19998, 4))
```

```
In [18]: # Приводимо дані до правильних типів

#1) Час у datetime
df["timestamp"] = pd.to_datetime(df["timestamp"])

#2) Назви груп в єдиний формат A/B
df["test_group"] = df["test_group"].astype(str).str.upper()

#3) conversion у 0/1
df["conversion"] = df["conversion"].astype(int)

df.dtypes
```

```
Out[18]: user_id      object
timestamp  datetime64[ns]
test_group      object
conversion      int64
dtype: object
```

```
In [19]: # Рахуємо кількість людей, кількість покупок, конверсію, коли йшов тест

# Users = унікальні користувачі
users = df.groupby("test_group")["user_id"].nunique()

# Conversion = сума conversion
conversions = df.groupby("test_group")["conversion"].sum()

# Conversion rate
cr = conversions / users
```

```
# Дати тесту
start_ts = df["timestamp"].min()
end_ts = df["timestamp"].max()
duration_days = (end_ts.date() - start_ts.date()).days + 1

users, conversions, cr, start_ts, end_ts, duration_days
```

```
Out[19]: (test_group
A      10013
B       9985
Name: user_id, dtype: int64,
test_group
A       611
B       889
Name: conversion, dtype: int64,
test_group
A      0.061021
B      0.089034
dtype: float64,
Timestamp('2023-07-03 01:42:34.033708'),
Timestamp('2023-07-25 01:41:19.152664'),
23)
```

```
In [20]: # Таблиця звітності. Тут ми отримуємо результати тесту: кількість користувачів,
summary = pd.DataFrame({
    "Group": users.index,
    "Users": users.values,
    "Conversions": conversions.reindex(users.index).values,
    "Conversions_rate": (cr.reindex(users.index).values * 100)
})

summary["Conversions_rate"] = summary["Conversions_rate"].round(2).astype(str) +
summary
```

```
Out[20]:
```

	Group	Users	Conversions	Conversions_rate
0	A	10013	611	6.1%
1	B	9985	889	8.9%

Обираємо критерій і рахуємо P-value

Для бінарної метрики (конверсії) правильний простий вибір - z-тест для двох часток

- Ми перевіряємо, чи різниця конверсій між A і B "реальна", а не випадкова.
- $p_value < 0.05$ - відхиляємо H_0 (нульову гіпотезу)

```
In [22]: from math import sqrt
from scipy.stats import norm

# Витягуємо числа (порядок A,B)
x_A = int(conversions["A"])
n_A = int(users["A"])
x_B = int(conversions["B"])
n_B = int(users["B"])

p_A = x_A / n_A
p_B = x_B / n_B
```

```

# pooled proportion
p_pool = (x_A + x_B) / (n_A + n_B)

# standart error
se = sqrt(p_pool * (1 - p_pool) * (1/n_A + 1/n_B))

z_stat = (p_B - p_A) / se
p_value = 2 * (1 - norm.cdf(abs(z_stat)))

# two-sided
alpha = 0.05
reject_h0 = p_value < alpha

p_A, p_B, z_stat, p_value, reject_h0

```

```

Out[22]: (0.06102067312493758,
          0.08903355032548824,
          7.519675939906207,
          np.float64(5.484501741648273e-14),
          np.True_)

```

Статистичний тест

Використано двосторонній z-тест для двох часток (two-proportion z-test).

- Конверсія групи A: 6.10%
- Конверсія групи B: 8.90%
- Різниця: +2.8 п.п.
- z-statistic: 7.52
- p-value: 5.48e-14 Оскільки p-value < 0.05, ми відхиляємо нульову гіпотезу. Отже, новий дизайн з повідомленням про знижку 50% статистично значуще збільшує конверсію.

```

In [23]: # Графік: Конверсія з 95% довірчими інтервалами
# Порівняння "середніх" конверсій + 95% CI
z_crit = 1.96


def ci_95(x, n):
    p = x / n
    se = sqrt(p * (1 - p) / n)
    return p, p - z_crit * se, p + z_crit * se

pA, loA, hiA = ci_95(x_A, n_A)
pB, loB, hiB = ci_95(x_B, n_B)

means = [pA, pB]
yerr = np.array([[pA - loA, pB - loB], [hiA - pA, hiB - pB]])

plt.figure(figsize=(6,4))
plt.bar(["A", "B"], means, yerr=yerr, capsize=8)
plt.ylabel("Conversion rate")
plt.title("Conversion rate by group (95% CI)")
plt.tight_layout()
plt.savefig("cr_with_ci.png", dpi=200)
plt.show()

```




```
In [24]: # Графік конверсії в часі
# Денна конверсія. Показує, як конверсія змінювалась щодня, і чи не було "дивних"
df["date"] = df["timestamp"].dt.date

daily = (df.groupby(["date", "test_group"])
        .agg(users=("user_id", "nunique"),
             conversions=("conversion", "sum"))
        )
daily["cr"] = daily["conversions"] / daily["users"]
daily = daily.reset_index()

plt.figure(figsize=(10,4))
for g in ["A", "B"]:
    tmp = daily[daily["test_group"] == g]
    plt.plot(tmp["date"], tmp["cr"], marker="o", label=g)

plt.ylabel("Daily conversion rate")
plt.title("Daily conversion rate over time")
plt.xticks(rotation=45)
plt.legend()
plt.tight_layout()
plt.savefig("cr_over_time.png", dpi=200)
plt.show()
```



Висновки та рішення

- Конверсія в групі А : 6,10%
- Конверсія в групі В : 8,90%
- Різниця (uplift) : +2,80 процентних пунктів

Статистичний тест : two-proportion, z-test $p_value = 5.48e-14$

Оскільки $p_value < 0,05$, ми відхляємо нульову гіпотезу. Різниця між групами статистично значуща.

Рішення

Впроваджуємо варіант В , оскільки:

- конверсія суттєво вища,
- результат статистично значущий,
- денна динаміка стабільна.

Новий дизайн з повідомленням про знижку 50% підвищує конверсію та рекомендований до повного rollout.

In []: